

CNN 모델에서의 정확도 향상을 위한 다양한 기법 탐구

1429 최현서

I. 서론

CNN 모델에서 성능을 높이는 방법들은 다양하게 존재한다. 그러한 방법 중, 보편적으로 사용되는 방법은 학습 데이터의 수를 높이거나 높은 해상도의 학습 데이터를 사용하는 방법이나 모델의 층을 깊게 만드는 방법 등, 여러 방안이 존재한다. 하지만 이 방식들은 학습 과정에서 과도한 연산량을 요구하기 마련이므로, 이러한 방법을 사용하지 않으면서 기본적인 CNN 모델에서 성능을 높이기 위한 방법들을 찾으려고 한다. (하이퍼파라미터 수정이나 가중치 규제, 배치 정규화, Dropout 등의 기법들은 이미 기본적인 모델에서도 사용되고 있는 기법이므로 이 방법들은 제외함.)

모델 구조를 더 깊게 만들지 않고 더 정확한 결과를 얻기 위해서 떠올릴 수 있는 방안은, 주어지는 데이터에 담긴 정보가 많을수록 예측이 쉬울 것으로 생각해 볼 수 있다. 그렇기 때문에 입력 데이터 사진에 담긴 정보를 최대한으로 사용하면, 모델 구조를 변형하지 않고도 성능을 높일 수 있다.

II. 본론

여기서는 두가지 방법을 사용할 것이다. 첫번째 방법은 이미지 향상 기법을 사용하는 것이고, 두번째 방법은 위상수학적 데이터 분석을 이용하여 재학습 하는 것이다. 기본적으로는 모두 pytorch를 사용하여 모델을 다룰 것이고, 일반적인 데이터 관리와 같은 부분은 numpy, 그리고 위상수학적 데이터 분석을 위해 giotto-tda를 이용하였으며, 데이터나 결과 등을 시각화 하기 위해서는 matplotlib을 사용하였다. 모든 학습이나 테스트에 이용된 데이터셋은 CIFAR-10을 사용하였다.

II-1. 이미지 향상 기법

이미지 향상 기법을 사용하면 모델이 이미지의 자세한 정보들을 고려하게 된다. 다음은 사용할 이미지 향상 기법의 종류이다.

히스토그램 평활화: 밝기 수준을 고르게 만들.

샤프닝 필터: 테두리(이미지 내의 물체에 대한 테두리)의 선명도를 향상시킴.


CLAHE: 대비를 높여 이미지의 디테일을 개선함.

다음과 같은 이미지 향상 기법을 적용한 후, 기존의 테스트 데이터와 향상 기법을 거



친 테스트 데이터에 대해 정확도와 F1 점수를 비교한다.

학습은 기존의 분류 정확도와 향상 기법을 사용한 모델의 정확도를 비교하는 것이니 절대적인 정확도가 높을 필요가 없어, 에포크는 1로 설정하였다. 학습률은 0.001을 사용하였고 배치 크기는 64이다. 분류를 위해 오차 함수는 CrossEntropy를 사용하고, 최적화 함수는 Adam을 사용해 학습을 진행하였다.

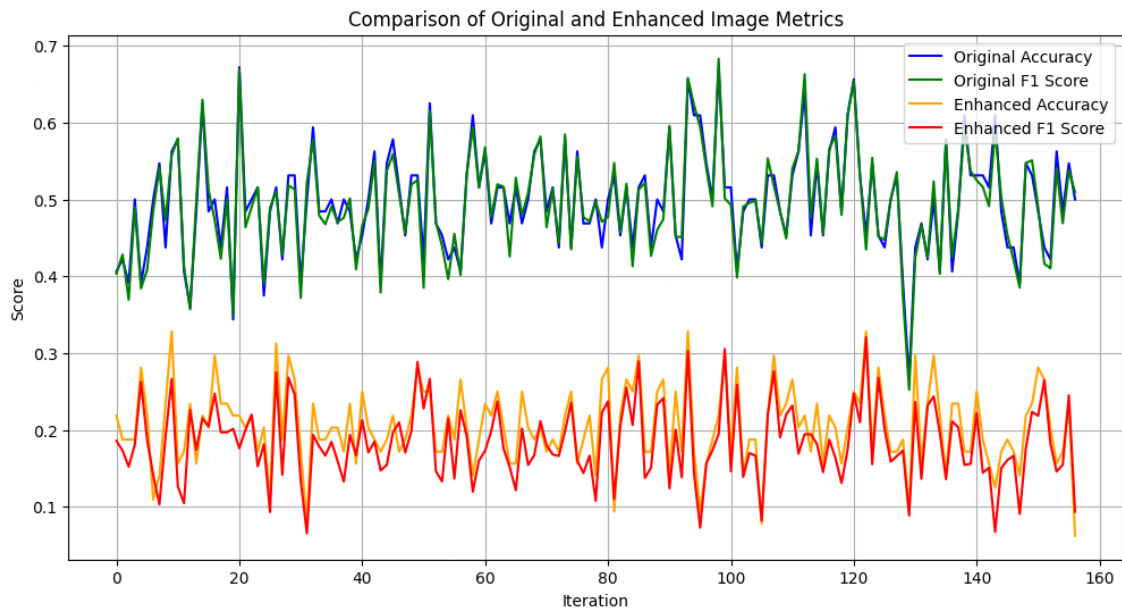


분류 학습은 이미지 향상이 적용되지 않은 이미지들로 학습하였다. 기본적인 분류기 모델과 동일한 구조를 가지고 있다. 정확도는 약 55% 정도로 나왔다.

```

[1, 1] loss: 2.323 acc: 0.125 f1: 0.103
[1, 101] loss: 1.509 acc: 0.375 f1: 0.365
[1, 201] loss: 1.318 acc: 0.484 f1: 0.489
[1, 301] loss: 2.046 acc: 0.406 f1: 0.446
[1, 401] loss: 1.676 acc: 0.375 f1: 0.384
[1, 501] loss: 1.546 acc: 0.500 f1: 0.496
[1, 601] loss: 1.319 acc: 0.531 f1: 0.513
[1, 701] loss: 1.302 acc: 0.594 f1: 0.591
[1, 1] acc: 0.562 f1: 0.554
[1, 101] acc: 0.562 f1: 0.558

```



원본 이미지와 향상을 거친 이미지를 비교해보니, 원본의 정확도는 40%~60% 이고 향상된 이미지의 정확도는 10%~30%정도로 나왔다.

예상과 다르게 정확도가 30%정도 낮게 나왔다. 나의 추측으로는, 이미지 향상을 통해 원본 이미지에 비해 이미지가 많이 변형되기도 하였고 물체 부분이 아닌 배경 부분도 강조하여 정확도가 낮게 나오는 경향이 있는 것 같다.


II-2. 위상수학적 데이터 분석 (TDA)

이 방법 또한 이미지 데이터에서 추가적인 정보를 발견하고 모델에 입력하는 방식이다. 그러나, 기존 이미지 데이터가 가지고 있던 정보를 증폭시키는 이미지 향상 기법과 달리, 이미지 데이터에서 물체의 기하학적 정보를 추출하여 모델에 추가적인 정보를 주는 방식으로 진행된다. 이미지 데이터에서 위상적 정보를 추출하기 위해서는 Persistence Homology를 통해 구해야 한다. 하지만 Persistence Homology는 점들


이 주어지는 데이터에서 정보를 추출하는 과정이기 때문에 포인트 클라우드 데이터에서만 적용 가능하다. 그렇기 때문에, 이를 위해 이미지를 포인트 클라우드 데이터로 변환하는 과정이 필요하다. 이미지를 포인트 클라우드 데이터로 변환하기 위한 작동 알고리즘은 다음과 같다.

1) 이미지 데이터 물체의 Edge를 추출한다. Edge 추출 알고리즘은 Canny Edge Detection을 사용한다.

2) 추출한 Edge를 새로운 이미지 데이터로 만든 뒤, Edge 부분의 픽셀만 활성화하고, 나머지 픽셀을 활성화하지 않는다.



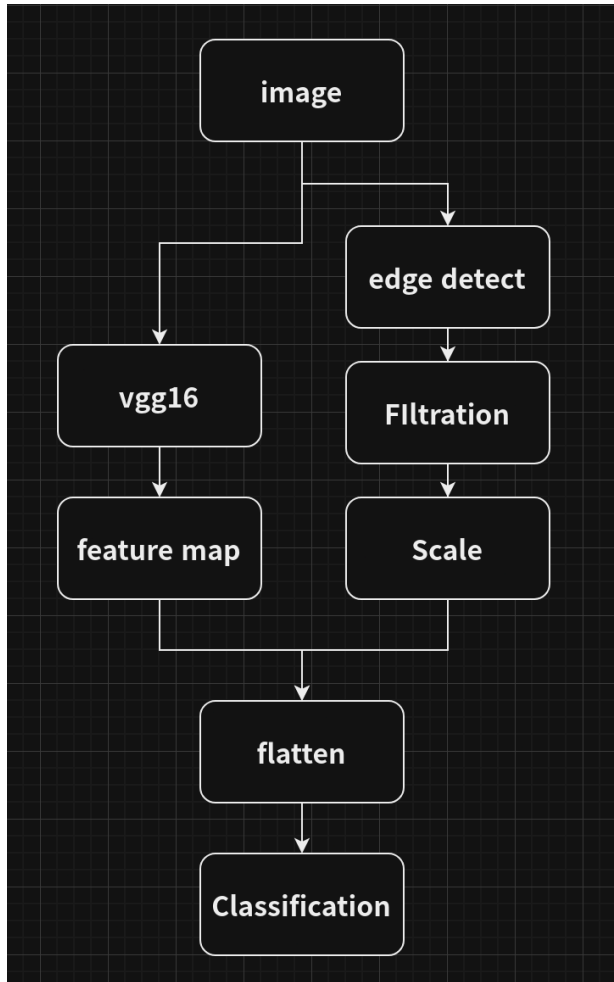
3) 그렇게 구한 이미지 데이터에 대해서 Cubical Complex를 구한다.



4) 바로 필터레이션을 진행하여 정보를 구할 수 있지만, 모델 입력을 위한 처리를 거치면 2차원의 벡터만 생겨 정보가 부족하다. 그렇기 때문에 이미지를 여러 부분으로 나누고, 각각의 중심을 기준으로 필터레이션을 진행해 얻은 모든 정보들을 추가해 더 많은 정보들을 얻는 과정을 진행한다.


5) 얻은 정보를 입력에 사용할 수 있도록 전처리한다.

이러한 알고리즘을 거쳐 이미지 데이터에 대한 위상적 정보, 물체의 형태에 대한 정보를 구하고 모델에 추가적인 정보를 줄 수 있게 된다. 구한 정보는 모델이 CNN 연산을 끝내고 분류 과정 직전에 거치는 층에 주어진다.




(TDA를 이용한 이미지 분류 향상을 위한 알고리즘)

이러한 알고리즘을 가지고 분류기만 학습하였다. 학습 시 설정한 하이퍼파라미터 설정은 이전의 분류기와 같다. (Epoch=1, lr = 0.001)




학습 결과는 정확도 50%~60% 정도로 나왔다. 이미지 향상 기법 테스트 시에 사용되었던 기존의 모델에 비해 대부분의 상황에서 정확도가 5~15% 정도 소폭 상승하였다. (기존의 모델과 구조는 다르지 않으며, 데이터나 하이퍼 파라미터 모두 동일한 환경에서 진행하였다.)



(tda를 이용한 모델의 붉은색 그래프가 미묘하게 높게 위치한 것을 알 수 있음)
 하지만 비교 결과, 기존 모델의 정확도가 높고, 새로 구상한 모델의 정확도가 더 낮은 경우가 존재했다. 왜냐하면 이미지 데이터의 테두리만 추출하는 과정에서 물체 뿐만

아니라 배경까지 테두리로 인식하는 경우가 있었는데, 그러한 경우에는 인식률이 낮게 나왔다.



물체의 테두리만 잘 추출된 이미지 예시 배경의 테두리까지 추출된 이미지 예시

Ⅲ. 결론

CNN 모델에서 모델 구조를 바꾸지 않고 성능을 향상하는 방법에 대해 탐구하였다. 이미지 향상 기법을 사용한 결과, 이미지의 배경까지 강조되어 성능이 감소되었고, 위상적 데이터를 이용하여 추가적으로 정보를 준 결과, 유의미한 성능의 차이가 존재했다. 두가지 방법 모두 배경에 대한 정보까지 추가적으로 입력하게 되어 물체 분류에서 걸림돌이 되었다. TDA를 이용하였을 때는 원래 목적이었던 CNN 모델 구조를 변형하지 않고 성능 향상하기를 성공하게 되었다. 하지만, giotto-tda가 gpu를 이용한 계산을 하지 못해 전처리 속도가 느려 추출할 수 있는 정보의 양을 줄였기 때문에 성능 향상폭이 유의미하게 나오지 않았다.

참고 문헌

- 히스토그램 평활화를 통한 이미지 개선
(HE: <https://developer-lionhong.tistory.com/183>)
(CLAHE: <https://hanstar4.tistory.com/36>)
- 이미지 샤프닝 필터링: <https://dream-and-develop.tistory.com/309>
- 이미지 인식에서의 TDA연구 : <https://www.nature.com/articles/s41598-020-77933-y>